CC3092 - Deep Learning y Sistemas Inteligentes

Laboratorio #8

Series de tiempo y forecasting

Instrucciones generales

- En parejas o individual.
- Entrega: Domingo 1 de noviembre, 2026. 23:59.

1. Datos

Trabajarán con ElectricityLoadDiagrams20112014 del UCI Machine Learning Repository: el consumo eléctrico de 370 clientes de Portugal entre 2011 y 2014, medido en kW cada 15 minutos.

Descarga y carga:

```
import urllib.request, zipfile
import pandas as pd

url = ("https://archive.ics.uci.edu/static/public/321/"
       "electricityloaddiagrams20112014.zip")
urllib.request.urlretrieve(url, "electricity.zip")
zipfile.ZipFile("electricity.zip").extract("LD2011_2014.txt")

raw = pd.read_csv("LD2011_2014.txt", sep=";", decimal=",",
                  index_col=0, parse_dates=True)   # 140,256 filas x 370 clientes
```

Definición del problema

Elemento	Definición
Variable objetivo	Consumo por hora por cliente, en kWh (agregar los 4 registros de 15 min)
Periodo	2012-01-01 a 2014-12-31; solo clientes con datos completos desde el 2012-01-01
Horizonte H	24 horas (pronóstico day-ahead emitido a las 00:00 con datos hasta las 23:00)
Entrenamiento	2012-01-01 a 2014-06-30
Validación	2014-07-01 a 2014-09-30 (selección de hiperparámetros y early stopping)
Prueba	2014-10-01 a 2014-12-31, backtesting con origen móvil diario (92 orígenes)

Si tienen restricciones de cómputo pueden usar un subconjunto de clientes (mínimo 100, elegidos con semilla fija), siempre que sea el mismo para todos los modelos.

2. Exploración y preparación de la serie

Construyan las primeras etapas del pipeline (datos crudos → series horarias limpias → ventanas → tensores) y respondan:

- ¿Cuántos clientes quedan después del filtro del periodo 2012–2014? ¿Cuántas observaciones horarias tiene cada serie y cuántas tiene el panel completo?
- ¿Cómo tratarán los dos días de cambio de horario de cada año?
- Grafiquen el perfil promedio por hora del día y por día de la semana, y marquen los feriados de Portugal. ¿Cómo cambia el consumo en Navidad y Año Nuevo?
- ¿Qué tan distintas son las escalas entre clientes (mínimo, mediana y máximo del consumo promedio)? Propongan y justifiquen una normalización: global, por serie (z-score con estadísticos de entrenamiento) o por ventana.
- Construyan las covariables de calendario conocidas a futuro (hora, día de la semana, mes, feriado) y expliquen cómo las codifican (one-hot, embeddings o seno/coseno).

Finalmente, implementen una clase Dataset de PyTorch que genere ventanas deslizantes con entrada X: (batch, L, features) y objetivo y: (batch, H) a partir de todas las series. Reporten cuántas ventanas de entrenamiento, validación y prueba produce el panel para L = 168, H = 24 y stride de 1 hora.

Auditoría de fugas. Para cada una de las cuatro fugas vistas en clase (split aleatorio de ventanas, escalar con toda la serie, early stopping con la prueba, covariables mal alineadas), muestren con código cómo su pipeline la evita. Recordatorio: cada entrada de la red debe poder calcularse en el instante en que se emite el pronóstico.

3. Investigación: herramientas para forecasting en PyTorch

Investiguen las clases, funciones y herramientas necesarias para construir, entrenar y evaluar los modelos. Para cada una, describan brevemente su propósito y sus parámetros más relevantes.

- nn.LSTM y nn.GRU (input_size, hidden_size, num_layers, batch_first, dropout) y la forma de sus salidas output, h_n y c_n.
- nn.Conv1d con dilation y padding causal: cómo se calcula el campo receptivo de una TCN.
- nn.TransformerEncoderLayer (d_model, nhead, dim_feedforward) y cómo se agrega la codificación posicional.
- NeuralForecast y StatsForecast de Nixtla: formato de entrada (unique_id, ds, y), el método cross_validation y sus parámetros n_windows, step_size y refit.
- BaseChronosPipeline.predict_quantiles de Chronos: entrada, prediction_length y quantile_levels.

Adicionalmente, investiguen brevemente los siguientes conceptos: modelo local (uno por serie) contra modelo global (uno para todas); teacher forcing en modelos autorregresivos y seq2seq; RevIN (reversible instance normalization) y por qué ayuda ante cambios de nivel; pinball loss y su relación con los cuantiles; y la diferencia entre MASE y WAPE como métricas de escala libre.

4. Protocolo de validación y métricas

Todos los modelos se evalúan con el mismo protocolo, implementado una sola vez como función backtest(modelo) que reciben todos los modelos.

- **Backtesting con origen móvil.** En prueba, el origen avanza 24 horas cada día (92 orígenes). En cada origen el modelo recibe solo los datos hasta las 23:00 del día anterior y pronostica las 24 horas siguientes. Los pesos se entrenan una vez con datos hasta el 2014-09-30.
- **Reentrenamiento.** Para el mejor modelo de deep learning y para el mejor baseline, repitan la prueba reentrenando al inicio de cada mes (3 orígenes con ventana expandible). ¿Cambia el error?

Métricas, calculadas en la escala original (kWh) y agregadas sobre todos los clientes y orígenes:

Métrica	Uso en este laboratorio
MAE y RMSE	En kWh; reportarlas también por cliente
WAPE	$\Sigma\|error\| / \Sigma\|real\|$ sobre todo el panel
MAPE	Calcúlenlo y expliquen qué le pasa con clientes de consumo cercano a cero

Para cada modelo reporten además el error por paso del horizonte ($h = 1, \ldots, 24$), el error por hora del día y el error en la semana del 22 al 28 de diciembre.

5. Construcción y entrenamiento de los modelos

Entrenen y evalúen con el protocolo de la sección 4 los siguientes modelos, todos sobre exactamente el mismo panel de clientes:

Familia	Modelos	Implementación
Baselines	Naive, seasonal naive (24 h y 168 h), MSTL o AutoETS	StatsForecast
Árboles	LightGBM global con rezagos (1–24, 168) y calendario	LightGBM
MLP y lineales	MLP multi-salida, DLinear y NLinear	PyTorch
Recurrentes	LSTM o GRU	PyTorch
Encoder–decoder	Seq2seq con covariables de calendario en el decoder	PyTorch
Residuales y convolucionales	N-HiTS o N-BEATS, y TCN	NeuralForecast
Atención	PatchTST y uno entre TFT e iTransformer	NeuralForecast
Probabilísticos	DeepAR	NeuralForecast o GluonTS

Familia	Modelos	Implementación
Fundacional	Chronos-Bolt (zero-shot, sin entrenamiento)	chronos-forecasting

5.1 Estrategias multi-paso

Con su LSTM, comparen las tres estrategias vistas en clase: autorregresiva (predice un paso y realimenta su predicción), multi-salida (una capa densa devuelve los 24 pasos) y encoder–decoder. Grafiquen el MAE por paso del horizonte de cada una. ¿Se observa la acumulación de errores de la estrategia autorregresiva?

5.2 Iteraciones de hiperparámetros

Al menos una de las iteraciones debe variar la ventana L (por ejemplo, 48, 168 y 336 horas) y otra la cantidad de historia de entrenamiento (por ejemplo, 3, 12 y 30 meses). Otros hiperparámetros a explorar: normalización, tamaño del estado oculto, número de capas, dropout, learning rate y tamaño de batch. Para la selección de configuraciones usen únicamente el bloque de validación; la prueba se usa una sola vez por modelo.

Para cada iteración, registren:

- La configuración de hiperparámetros usada, incluyendo L, H y los meses de historia.
- La pérdida de entrenamiento y validación por epoch.
- Al final de cada epoch: MAE y MASE en validación.
- Parámetros totales y entrenables.
- El tiempo de entrenamiento por epoch y total, el tiempo de inferencia sobre los 92 orígenes y la memoria pico de GPU.

Grafiquen las curvas de pérdida de al menos 3 iteraciones. ¿Una pérdida de entrenamiento más baja implica siempre un mejor MASE en validación?

5.3 Modelo local contra global

Entrenen su mejor modelo propio de dos formas: un modelo por cliente (para 10 clientes) y el modelo global. Comparen el MASE en esos 10 clientes.

6. Comparación de resultados

Construyan una tabla comparativa con la mejor configuración de cada modelo de la sección 5 que incluya:

- Familia, ventana L, estrategia multi-paso y si usa covariables.
- Parámetros totales y entrenables.
- Tiempo de entrenamiento, tiempo de inferencia y hardware utilizado (para Chronos, solo inferencia).
- MAE, RMSE, WAPE y MASE en prueba con H = 24, y MASE con H = 168 cuando aplique.
- MASE en la semana del 22 al 28 de diciembre.
- Pinball loss y cobertura P10–P90 para los modelos probabilísticos.

Ordenen la tabla por MASE.

Adicionalmente, generen al menos tres gráficas: (1) MASE de prueba contra tiempo de entrenamiento en escala log, un punto por modelo, para identificar la frontera de Pareto; (2) MAE por paso del horizonte (h = 1, …, 24), una curva por modelo; y (3) MASE contra meses de historia de entrenamiento (sección 5.2) para el seasonal naive, LightGBM, DLinear, su mejor recurrente y PatchTST, con Chronos como línea de referencia.

8. Discusión y análisis

Respondan con base en sus resultados:

- ¿Qué modelo ganó y por cuánto superó al seasonal naive? ¿La mejora justifica su costo de entrenamiento y de mantenimiento en producción?
- ¿Se replica en sus datos el hallazgo de DLinear de que un modelo lineal compite con los Transformers? ¿En qué horizonte?
- ¿Qué estrategia multi-paso funcionó mejor y por qué? ¿Cómo crece el error con el paso del horizonte en cada familia?
- ¿Qué efecto tuvieron la ventana L, la normalización y la cantidad de historia? ¿A partir de cuántos meses de historia el deep learning supera a LightGBM y a los estadísticos?
- ¿Convino un modelo global o uno por cliente? ¿Qué clientes se benefician más del modelo global?
- ¿Qué tan cerca quedó Chronos zero-shot de los modelos entrenados? ¿En qué situación lo usarían en lugar de entrenar una red?
- ¿Qué pasó en Navidad y Año Nuevo? ¿Las covariables de feriado ayudaron, o el cambio de régimen afectó a todos los modelos por igual?
- ¿Qué tan sensibles fueron sus resultados a la semilla? Repitan su mejor modelo con 3 semillas y reporten la desviación estándar del MASE.

Entregables

Entregable	Contenido
PDF (máx. 5 páginas)	Investigación, decisiones de preparación de la serie y auditoría de fugas, tabla de iteraciones, comparación de estrategias multi-paso, tabla comparativa de todos los modelos, resultados probabilísticos, gráficas, análisis y conclusiones.
Repositorio (Git)	Jupyter Notebook completo y comentado: carga y limpieza, exploración, Dataset de ventanas, función backtest, implementaciones propias (MLP, DLinear, NLinear, LSTM, seq2seq), entrenamiento de las iteraciones, modelos de librería, pronóstico probabilístico, visualizaciones y evaluación final sobre prueba. Incluyan un archivo con los pronósticos de prueba de cada modelo (unique_id, ds, modelo, y_hat).

Incluyan el enlace al repositorio al final del PDF.